1- Problématique

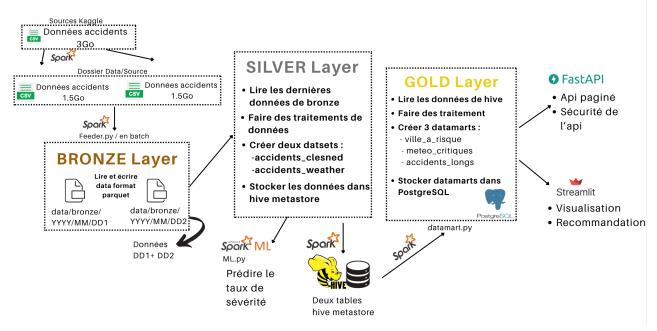
Les accidents de la route représentent un enjeu majeur pour la sécurité et la gestion des risques, nécessitant une exploitation efficace de données massives et hétérogènes. Dans ce contexte, la capacité à prédire la sévérité d'un accident à partir de données historiques (trafic, météo, localisation, etc.) offre des perspectives concrètes pour l'aide à la décision des assureurs, pouvoirs publics et services d'urgence.

2- Business Value

La prédiction de la sévérité des accidents de la route grâce à l'analyse de données massives (trafic, météo, géolocalisation) permet :

- Anticipation du risque : Identifier les zones et conditions météo les plus à risque pour orienter la prévention.
- Aide à la décision : Donner aux assureurs, pouvoirs publics et services d'urgence des informations exploitables en temps réel pour mieux cibler leurs actions.
- Optimisation des ressources : Prioriser l'allocation des secours, adapter la gestion du trafic et optimiser les interventions.
- Personnalisation des offres d'assurance : Ajuster les polices et tarifications selon le niveau de risque géolocalisé.
- Réduction des coûts : En diminuant la sinistralité et en intervenant plus efficacement, on limite les conséquences humaines et matérielles.

3- Architecture



4- Dossiers principaux

data/

• bronze/: fichiers Parquet partitionnés (données brutes, formaté par date).

- **source/**: fichiers CSV sources à ingérer.
- seen_files.txt : registre des fichiers déjà traités pour l'ingestion incrémentale.
- (Autres fichiers): fichiers de configuration pour Hive Metastore et docker

notebooks/

- logs/: tous les fichiers de log générés par les scripts.
- **UTILS.py**: fonctions réutilisables (création SparkSession, gestion des fichiers lus, détection nouveaux fichiers, fusion...).
- **split_and_tag.py** : script pour diviser le gros fichier Kaggle en deux sous-fichiers CSV.

Feeder.py:

- Gère l'ingestion incrémentale des fichiers bruts depuis /data/source/ vers la couche Bronze.
- Détecte automatiquement les nouveaux fichiers grâce à un registre seen_files.txt
- Extraire la date depuis le nom du fichier et organise des données dans des dossiers partitionnés : data/bronze/YYYY/MM/DD/
- Fusionne les nouvelles données avec les anciennes pour éviter toute perte.
- Stocke les données au format Parquet
- Chaque partition journalière est écrite avec 2 partitions Spark
- Journalisation détaillée dans un fichier log pour assurer le suivi et le débogage.

Preprocessor.py:

- traite le dernier dossier de la couche Bronze (/data/bronze/YYYY/MM/DD/), pour garantir que seul le batch de données le plus récent est pris en compte.
- Les données sont lues au format Parquet, ce qui accélère le chargement et optimise le stockage.
- Traitement automatique des données : conversion des timestamps, calcul de la durée d'accident, typage et gestion des colonnes numériques/catégorielles (remplacement des valeurs manquantes, cast, ajout de colonnes utiles)
- Le DataFrame Spark est persisté en mémoire/disque (df.persist(StorageLevel.MEMORY_AND_DISK)) pour améliorer la performance lors des traitements.
- Les données sont repartitionnées en 2
- Deux datasets créés : un pour les accidents, un pour la météo, tous deux sauvegardés dans Hive (Silver Layer) sous forme de tables Parquet
- Logging détaillé pour chaque étape (début, fin, succès Hive...)

ML.py:

- Lit les jeux de données accidents et météo depuis Hive (Silver), puis les fusionne via la colonne ID
- Sélectionne et prépare les features numériques utiles à la prédiction de la sévérité.
- Supprime les lignes incomplètes pour garantir la qualité des données.
- Split les données en train/test (80/20).
- Crée un pipeline Spark ML:
 - Assembler des features,
 - o StandardScaler (mise à l'échelle),
 - RandomForestClassifier (forêt aléatoire, 50 arbres).
- Entraîne le modèle sur le train et prédit sur le test.
- Évalue les performances avec 4 métriques principales (accuracy, precision, recall, f1).
- Loggue tout le processus

datamart.py:

- Charge les données nettoyées (accidents + météo) depuis Hive et effectue une jointure sur la colonne ID.
- Crée 3 datamarts analytiques :
 - villes_a_risque : top villes avec le plus d'accidents graves (≥3), statistiques agrégées.
 - o **meteo_critiques** : conditions météo associées à la gravité, fréquence, humidité, vent, précipitations.
 - o **accidents_longs**: top 100 accidents de plus longue durée, avec infos météo associées.
- Les résultats sont écrits directement dans PostgreSQL (schéma datamarts) via le connecteur JDBC, en mode overwrite.
- Journalisation complète pour assurer la traçabilité et le suivi d'exécution.

Api.py:

- Expose une API REST (FastAPI) pour accéder aux datamarts stockés dans PostgreSQL, avec authentification par jeton (API_TOKEN) pour sécuriser les endpoints.
- lire les tables postgresql via JDBC
- Principales routes:
 - o /health: test simple pour vérifier si l'API fonctionne.
 - o /datamarts/{table_name} : pagination sur une des 3 tables
 (accidents_longs, meteo_critiques, villes_a_risque), résultat en
 liste de dictionnaires.
 - o /datamarts/{table_name}/schema: retourne le schéma de la table (nom/type de chaque colonne).
 - o /datamarts/{table_name}/count: retourne le nombre de lignes total
 d'une table.
 - o /datamarts/{table_name}/search: permet de chercher une valeur dans une colonne (filtre LIKE, pagination incluse).

- **Sécurité**: Chaque endpoint sensible requiert un token d'authentification HTTP Bearer.
- **Architecture réutilisable** : chaque opération de lecture est factorisée dans des fonctions, la gestion du SparkSession et la configuration sont mutualisées avec UTILS.py.

streamlit.py:

- Dashboard développé avec Streamlit, connecté directement à la base PostgreSQL des datamarts.
- Top 10 villes à risque (accidents graves)
- Durée moyenne d'accident (top 10 villes)
- Top 10 conditions météo les plus dangereuses (par sévérité moyenne)
- Top 5 conditions météo les plus accidentogènes
- Distribution de la sévérité des accidents

5- Justificatif des paramètres dans spark-submit

Pour bronze on a mis:

spark-submit \

- --master yarn \
- --deploy-mode client \
- --conf spark.sql.shuffle.partitions=2 \
- --conf spark.driver.memory=2g \
- --conf spark.executor.memory=1g \
- --conf spark.executor.cores=2\

datamart.py

- -2 partitions chacune environ 460Mo => On a choisi **1Go** par exécuteur pour avoir une marge confortable et éviter les erreurs mémoire
- on a mis **2 cores** par exécuteur pour permettre le traitement parallèle des deux partitions
- conf spark.sql.shuffle.partitions=2 identique à ce que j'ai mis lors de l'écriture des fichiers (df ;repartition(2)

Pour Silver et Datamart_postgres :

-On a mis **2 cores** et 2**Go** de mémoire par executor parce qu'on a des jointures et des opérations de traitements de données comme la conversation de type qui consomme plus de RAM qu'une simple ingestion brute

Pour ML_severity:

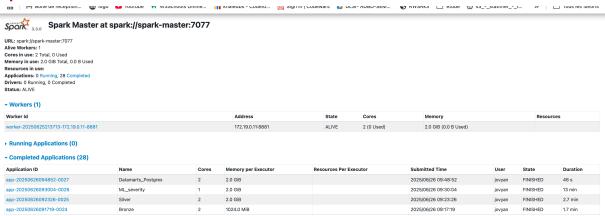
Pour l'entraînement du modèle, on a mis **1 seul core** par exécuteur, car les algorithmes de Machine Learning Spark, comme RandomForest, ne tirent pas toujours parti du parallélisme sur plusieurs cores lorsque la taille de données est modérée

-2 Go de mémoire à l'executor pour garantir que la phase d'entraînement du modèle (Random Forest) puisse charger en mémoire un volume suffisant de données, ainsi que tous les objets Spark nécessaires (features, labels, pipeline, modèle, etc).

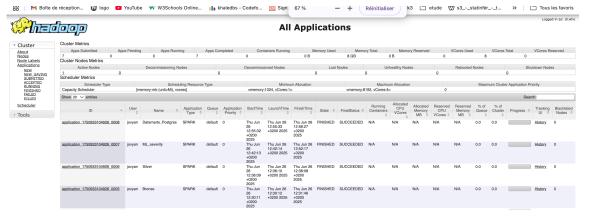
6- Arborescence dossier après le feeder

v 📺 data	aujourd'hui à 12:23	
∨ 🛅 bronze	avant-hier à 10:44	
∨ 🛅 2025	avant-hier à 10:44	
∨ 🛅 01	aujourd'hui à 12:30	
∨ 🛅 01	avant-hier à 10:42	
SUCCESS	avant-hier à 10:42	Zéro octet
part-00000-c39c184b-d37a185a10c1-c000.snappy.parquet	avant-hier à 10:42	218,1 Mo
part-00001-c39c184b-d37a185a10c1-c000.snappy.parquet	avant-hier à 10:42	218,3 Mo
∨ ■ 02	aujourd'hui à 12:31	
_SUCCESS	aujourd'hui à 12:31	Zéro octet
part-00000-b5493f3d-60beafcda5fc-c000.snappy.parquet	aujourd'hui à 12:31	464,1 Mo
part-00001-b5493f3d-60beafcda5fc-c000.snappy.parquet	aujourd'hui à 12:31	464,1 Mo

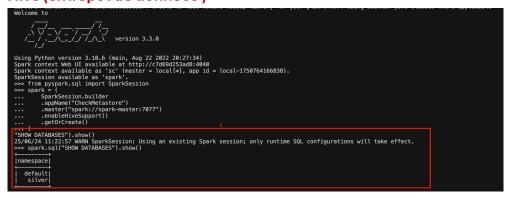
7- Spark UI



8- Yarn UI



9- Hive (entrepôt de données)



+ ID Weather_Timestamp her_Condition	Temperature_F	Wind_Chill_F	Humidity_pct	Pressure_in	Visibility_mi	Wind_Direction	Wind_Speed_mph	Precipitation_in
		·		·			·	+
A-667842 2022-03-22 21:53:00	13.0	0.0	81.0	20.82	10.0	NNE	10.0	0.01
Mostly Cloudy								
A-1470683 2020-05-15 12:50:00 Mostlv Cloudv	86.0	86.0	51.0	29.76	10.0	E	16.0	0.0
A-309318 2016-11-03 17:53:00	60.1	0.0	72.0	30.17	10.0	Calmi	0.01	0.01
Clear	0011	0.0	7210	3011/	1010	Cu ciii	0.01	0101
A-1306350 2020-09-20 08:55:00 Fairl	69.0	69.0	65.0	29.86	8.0	SW	3.0	0.0
A-1338245 2020-10-13 14:54:00 Fair	75.0	75.0	23.0	29.27	10.0	NE	5.0	0.0

10-PostgreSQL (datamarts)

```
PROBLEMS 2 OUTPUT DEBUG CONSOLE TERMINAL PORTS
(base) hadilneji@Host-003 Bigdata 3 % psql -h localhost -U spark -d datamarts -p 5433
Password for user spark:
psql (17.5, server 15.13 (Debian 15.13-1.pgdg120+1))
Type "help" for help.
datamarts=# SELECT * FROM villes_a_risque LIMIT 3;
City | State | Nombre_Accidents_Graves | Severite_Moyenne | Duree_Moyenne_Accident
Los Angeles | CA
Dallas | TX
Atlanta | GA
(3 rows)
                                                         35866 | 3.026180784029443 |
34142 | 3.033214222951204 |
33842 | 3.0837420956208264 |
                                                                                                         68.40868789382702
                                                                                                         95.63894909495636
71.68657289758289
Cancel request sent
datamarts=# datamarts=# SELECT * FROM meteo_critiques LIMIT 3;
Weather_Condition | Moy_Severity | Nb_Accidents |
                                                                                        Humidite_Moy | Vitesse_Vent_Moy | Precipitations_Moy
                                                                                Light Blowing Snow
Patches of Fog / Windy
Partial Fog / Windy
(3 rows)
                                   3.666666666666665
3.142857142857143
| Duration_Minutes | Severity | Weather_Condition | Wind_Speed_mph | Precipitation_in
A-4810425 | Wilmington | DE
A-5053641 | Wilmington | DE
A-5399002 | Southampton | NY
(3 rows)
                                              2016-10-21 07:26:00
2016-10-21 07:26:00
2018-04-19 09:24:00
datamarts=#
```

Loggers

Feeder log

Preprocessor log

```
2025-06-26 10:36:05,413 [INFO] Logs seront écrits dans /home/jovyan/work/logs/preprocessor.log
2025-06-26 10:36:05,415 [INFO] Dossier parquet le plus récent : /data/bronze/2025/01/02
2025-06-26 10:36:23,191 [INFO] ▼ DataFrame persisted en MEMORY_AND_DISK
2025-06-26 10:37:47,662 [INFO] Nombre de lignes dans le batch : 7728394
2025-06-26 10:38:02,418 [INFO] ▼ Table accidents sauvegardée dans Hive : silver.accidents_cleaned
2025-06-26 10:38:08,706 [INFO] ▼ Table météo sauvegardée dans Hive : silver.accidents_weather
2025-06-26 10:38:08,707 [INFO] ▼ Temps de traitement de la dernière partition : 108.17 sec
2025-06-26 10:38:09,235 [INFO] ▼ Temps total d'exécution du preprocessor : 123.82 sec
2025-06-26 10:38:09,236 [INFO] Closing down clientserver connection
```

Datamarts log

```
2025-06-26 10:55:28,092 [INFO] Logs seront écrits dans /home/jovyan/work/logs/datamarts.log
2025-06-26 10:55:28,093 [INFO] Les datamarts seront stockés dans la base Postgres : jdbc:postgresql://postgres:5432/datamarts
2025-06-26 10:55:45,097 [INFO] Chargement des données depuis Hive...
2025-06-26 10:55:46,556 [INFO] Jointure accidents + météo OK.
2025-06-26 10:55:46,598 [INFO] Datamart 1 'villes_a_risque' prêt.
2025-06-26 10:55:46,614 [INFO] Datamart 2 'meteo_critiques' prêt.
2025-06-26 10:55:46,624 [INFO] Datamart 3 'accidents_longs' prêt.
2025-06-26 10:55:46,625 [INFO] → Écriture du datamart 'villes_a_risque' dans jdbc:postgresql://postgres:5432/datamarts ...
2025-06-26 10:56:04,585 [INFO] → Écriture du datamart 'meteo_critiques' dans jdbc:postgresql://postgres:5432/datamarts ...
2025-06-26 10:56:04,585 [INFO] → Écriture du datamart 'meteo_critiques' dans jdbc:postgresql://postgres:5432/datamarts ...
2025-06-26 10:56:14,853 [INFO] → Écriture du datamart 'accidents_longs' écrit avec succès.
2025-06-26 10:56:14,854 [INFO] → Écriture du datamart 'accidents_longs' dans jdbc:postgresql://postgres:5432/datamarts ...
2025-06-26 10:56:14,854 [INFO] → Écriture du datamart 'accidents_longs' dans jdbc:postgresql://postgres:5432/datamarts ...
2025-06-26 10:56:27,723 [INFO] → Datamart 'accidents_longs' écrit avec succès.
2025-06-26 10:56:27,723 [INFO] → Temps total d'exécution du pipeline datamarts : 59.03 sec
2025-06-26 10:56:27,725 [INFO] Closing down clientserver connection
```

ML log

```
2025-06-26 10:49:34,766 [INFO] Accuracy: 0.797

2025-06-26 10:50:23,266 [INFO] Weightedprecision: 0.634

2025-06-26 10:51:07,781 [INFO] Weightedrecall: 0.797

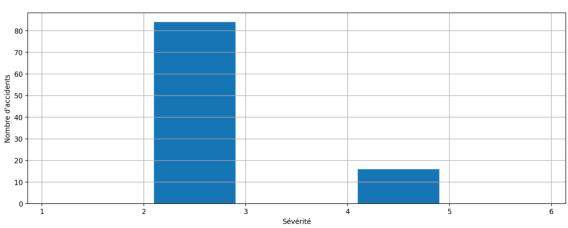
2025-06-26 10:51:51,179 [INFO] F1: 0.706

2025-06-26 10:52:17,071 [INFO] Temps d'exécution total (sec): 607.68

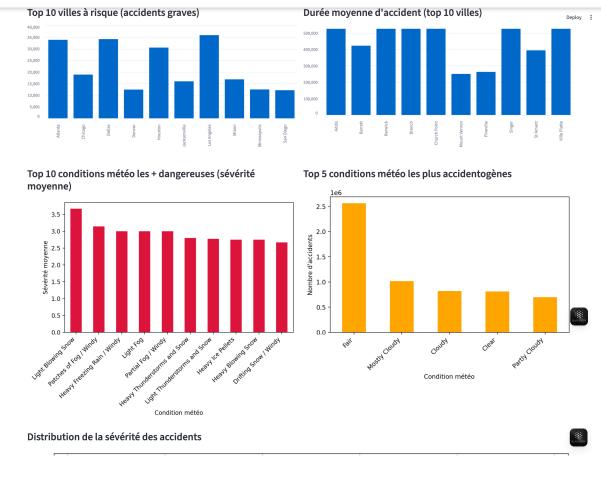
2025-06-26 10:52:17,080 [INFO] Closing down clientserver connection
```

11-Visualisation





Deploy :



_	s à risque	-												D
	City		State	Nomb	ore_Accidents	_Graves		Severite_Mc	yenne		Duree_Moye	nne_Acciden	t	
0	Los Angeles		CA				35866			3.026	2		68.4087	7
1	Dallas		TX				34142			3.033	2		95.6389	9
2	Atlanta		GA				33842			3.083	7		71.6866	6
3	Houston		TX				30498			3.036	1		155.7756	6
4	Chicago		IL				18867			3.052	7		141.5142	2
)	Weather_Conditi		Moy_Sever		Nb_Accidents		Humidite_I			Vitesse_Vent_Moy	15 3333	Precipitation		0
té	éo critiqu	es												
)	Light Blowing Sn	iow		3.6667	6667 3		58.6667		15.3333		·		0	
1	Patches of Fog / Windy		3.1429	429 7			86.1429		24		(0		
2	Partial Fog / Windy			3	3 1		81		24		0		0	
3	Light Fog		3	3 4			100		9.525		0		0	
4	Heavy Freezing Rain / Windy			3	1			88		21		0.15		5
i	dents lon	i gs		Start Time		Duration Minutes				r Condition	W. 10 1			
			State				Sevi				Wind_Speed_m		Precipitation_in	
	A-4810425	Wilmington	DE	2016-10-21 07:26			12939		Overcas			8.1	(
	A-5053641	Wilmington	DE	2016-10-21 07:26			12939		Overcas			8.1	(
	A-5399002	Southampton	NY NY	2018-04-19 09:24			36406		Overcas			5.8	(
2	A-4014778						36356		Overcas			5.8		

12-Recommandation

Les dashboards montrent que certaines villes enregistrent un nombre élevé d'accidents graves et une durée moyenne d'accident importante.

Recommandation : Lancer des campagnes de sensibilisation ciblées et

améliorer la signalisation dans ces villes, surtout aux périodes où la sinistralité est la plus forte.

 Les graphiques mettent en évidence les conditions météo les plus dangereuses et accidentogènes (comme le brouillard, la neige ou le vent fort).

Recommandation : Alerter les usagers et adapter la gestion du trafic lors de ces conditions : messages d'alerte, limitation temporaire de vitesse, déploiement de patrouilles sur les axes concernés.